

INSTITUTO DE FORMACIÓN TÉCNICA SUPERIOR N° 18

Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial

TRABAJO PRÁCTICO FINAL

Proyecto Integrador

Dataset Supermarket_Sales (2014 – 2017)

Integrantes del equipo

Gabriel D'Annunzio · Juan Manuel Etchehun · Pablo Tapia · Pablo Donato Nuñez

Profesor: Hugo Planiscig- Materia: Proyecto Integrador — Ciclo lectivo 2026

Ciudad Autónoma de Buenos Aires

Índice de contenidos

1. Introducción
2. Objetivos del proyecto
3. Descripción del dataset
4. Metodología de trabajo
5. Limpieza y transformación de datos
6. Variables derivadas
7. Análisis exploratorio de datos y visualizaciones
8. Análisis RFM y segmentación de clientes
9. Insights de negocio
10. Conclusiones generales
11. Recomendaciones y mejoras futuras
12. Anexo técnico — Notebook de Google Colab

1. Introducción

El presente informe sintetiza el desarrollo, los resultados y los aprendizajes del Trabajo Práctico Final correspondiente a la asignatura Proyecto Integrador de la Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial del IFTS N° 18. La consigna planteó la realización de un Análisis Exploratorio de Datos (EDA) sobre un dataset transaccional perteneciente a una cadena de supermercados de los Estados Unidos, con información de ventas correspondientes a un período de tres años. El objetivo último de la actividad consiste en transformar datos crudos —y deliberadamente afectados por inconsistencias de calidad— en información accionable que pueda ser presentada al negocio mediante un tablero analítico en Power BI.

El abordaje del trabajo siguió una lógica progresiva, partiendo del diagnóstico estructural del dataset, avanzando hacia el preprocesamiento y la transformación de variables, y culminando con un análisis multidimensional de los principales drivers comerciales: categoría de producto, segmento de cliente, región geográfica, política de descuentos y modalidad de envío. La preparación del dato no se entendió como una etapa accesoria sino como el componente más extenso y crítico del proyecto, dado que la integridad de cualquier insight derivado depende directamente de la calidad del corpus utilizado.

Este documento se organiza siguiendo el flujo natural de un proyecto analítico: contextualización del problema, descripción de la fuente de datos, decisiones metodológicas durante la limpieza, hallazgos del análisis exploratorio acompañados de sus visualizaciones, y finalmente recomendaciones orientadas a la toma de decisiones del negocio.

2. Objetivos del proyecto

Objetivo general

Realizar un Análisis Exploratorio de Datos sobre el conjunto Supermarket_Sales con el fin de identificar patrones de compra, evaluar el desempeño comercial y extraer hallazgos accionables que permitan al negocio orientar sus decisiones estratégicas y operativas.

Objetivos específicos

- **Diagnosticar la calidad del dataset** inicial, identificando inconsistencias estructurales, tipográficas y de tipado.
- **Aplicar un proceso de limpieza y preprocesamiento** reproducible, justificando cada decisión metodológica.
- **Construir variables derivadas** que enriquezcan el análisis (margen de utilidad, días de envío, agregaciones temporales).
- **Obtener estadísticas descriptivas** sobre las variables numéricas clave y comprender la forma de sus distribuciones.

- **Detectar patrones comerciales** a través de cortes por categoría, subcategoría, región, segmento y tiempo.
- **Analizar la relación entre política de descuentos y rentabilidad**, identificando umbrales críticos para la salud financiera de la operación.
- **Segmentar la cartera de clientes mediante análisis RFM** (Recency, Frequency, Monetary) para identificar grupos accionables comercialmente.
- **Generar visualizaciones interpretables** y traducir cada gráfico en una lectura de negocio concreta.
- **Producir un dataset limpio y enriquecido** listo para ser consumido por una herramienta de Business Intelligence (Power BI).
- **Formular recomendaciones** accionables que potencien el negocio a partir de los hallazgos del EDA.

3. Descripción del dataset

El conjunto de datos utilizado, denominado `df_sales_crudo.csv`, contiene 9.994 registros transaccionales y 21 columnas que describen pedidos realizados en una cadena de supermercados de los Estados Unidos durante un período de aproximadamente tres años (2014 – 2017). Cada fila corresponde a una línea de pedido, es decir, a un producto individual dentro de una orden de compra: en consecuencia, una misma orden (Order ID) puede repetirse en múltiples filas si incluye más de un ítem.

El dataset combina información de naturaleza heterogénea: identificadores únicos, fechas operativas, datos geográficos, atributos del cliente, atributos del producto y métricas comerciales. A continuación se sintetiza el esquema lógico de las variables disponibles:

Grupo	Variables	Naturaleza
Identificadores	Row ID, Order ID, Customer ID, Product ID	Claves operativas
Temporales	Order Date, Ship Date	Fechas del ciclo de venta
Logísticas	Ship Mode	Modalidad de envío
Cliente	Customer Name, Segment	Atributos del comprador
Geográficas	Country, City, State, Postal Code, Region	Ubicación del pedido
Producto	Category, Sub-Category, Product Name	Jerarquía comercial
Métricas	Sales, Quantity, Discount, Profit	Variables económicas

Una particularidad relevante del dataset es que fue intencionalmente «ensuciado» con el propósito pedagógico de simular las condiciones reales que enfrenta un analista en su práctica profesional. Entre las anomalías encontradas se identificaron: tipos de datos incorrectos (columnas numéricas almacenadas como texto), valores corruptos con etiquetas explícitas como `Corrupted_Sale`, `Invalid_Qty` o

DATE_ERROR_FORMAT, errores tipográficos sistemáticos en variables categóricas (Sceond Class, StandardClass, Cnosumer, Furniutre, etc.), pérdida de ceros a la izquierda en códigos postales por interpretación numérica, y valores nulos distribuidos en nueve columnas distintas con porcentajes que oscilan entre el 1,96 % y el 2,33 %.

4. Metodología de trabajo

La estrategia metodológica adoptada por el equipo combinó buenas prácticas de la ingeniería de datos con los lineamientos del enfoque CRISP-DM, adaptados a la escala de un proyecto académico. El flujo de trabajo se estructuró en cinco fases secuenciales pero iterativas, permitiendo visitar etapas anteriores cuando el análisis lo requiera.

Fases del trabajo

- **Comprensión del negocio:** lectura de la consigna, identificación de las preguntas analíticas relevantes para una cadena de retail (¿qué se vende?, ¿quién compra?, ¿dónde?, ¿cuándo?, ¿con qué margen?) y planificación del cronograma de entregas.
- **Comprensión de los datos:** carga del archivo crudo desde Google Drive, inspección de dimensionalidad (filas, columnas), revisión de tipos de datos declarados por pandas y diagnóstico inicial de calidad mediante conteos de nulos y duplicados.
- **Preparación de los datos:** conversión de tipos, normalización de variables categóricas, tratamiento de nulos, recuperación de códigos postales y construcción de variables derivadas. Esta fue la etapa más extensa del proyecto y la que mayor valor aporta al producto final.
- **Análisis exploratorio:** cálculo de estadísticas descriptivas, agregaciones por dimensiones de interés (categoría, región, segmento, tiempo) y producción de visualizaciones interpretativas.
- **Comunicación de resultados:** exportación del dataset depurado a formato Excel para su consumo desde Power BI y elaboración del presente informe como soporte documental.

Stack tecnológico

El trabajo se desarrolló íntegramente en Google Colab utilizando Python 3 y el ecosistema científico estándar: pandas y NumPy para manipulación de datos, Matplotlib y Seaborn para visualización, y módulos auxiliares de la biblioteca estándar (re, pathlib, difflib) para tareas de limpieza textual. La capa de presentación se construyó posteriormente en Power BI a partir del dataset depurado.

5. Limpieza y transformación de datos

El equipo asumió la premisa de que un dataset crudo nunca debe modificarse en su lugar; por ello se trabajó siempre sobre una copia (df) preservando el original (df_raw) como respaldo trazable. Las decisiones de limpieza se documentaron en el notebook explicando no sólo el «qué» sino el «por qué» de cada transformación.

5.1 Diagnóstico inicial

El primer paso consistió en cuantificar la magnitud de los problemas. El diagnóstico arrojó los siguientes resultados:

Dimensión	Valor
Filas totales	9.994
Columnas totales	21
Filas duplicadas exactas	0
Columnas con valores nulos	9
Nulos máximos en una columna	233 (City) – 2,33 %
Variables con tipo incorrecto	Sales, Quantity, Order Date, Ship Date, Postal Code
Valores corruptos en Sales	50 (ej.: Corrupted_Sale)
Valores corruptos en Quantity	50 (ej.: Invalid_Qty)
Valores corruptos en Order Date	30 (ej.: DATE_ERROR_FORMAT)

5.2 Conversión de tipos de datos

Sales y Quantity, aunque conceptualmente numéricas, llegaron almacenadas como texto debido a la presencia de etiquetas corruptas mezcladas con los valores legítimos. Se aplicó la función `pandas.to_numeric` con el parámetro `errors='coerce'`, estrategia que convierte los valores válidos al tipo numérico y reemplaza los inválidos por NaN, sin interrumpir la ejecución. Idéntico criterio se aplicó a Order Date y Ship Date con `pandas.to_datetime`, logrando recuperar la totalidad de fechas válidas y aislando las 30 entradas corruptas.

Caso especial: Postal Code

El tratamiento del código postal merece una mención específica porque ilustra un error conceptual frecuente entre analistas principiantes. Aunque sintácticamente parece numérico, semánticamente Postal Code es un identificador alfanumérico: no admite operaciones aritméticas significativas (no tiene sentido calcular el promedio de códigos postales) y en los Estados Unidos numerosos códigos comienzan con cero, dígito que se pierde irremediabilmente cuando la variable se interpreta como entero. El diagnóstico reveló 449 códigos de cuatro dígitos —todos ellos códigos válidos que habían perdido su cero inicial—. La solución consistió en convertir la columna a tipo string y aplicar `str.zfill(5)` para restaurar los ceros faltantes, garantizando que todas las entradas conservaran su longitud original de cinco dígitos.

5.3 Normalización de variables categóricas

Las columnas Ship Mode, Segment y Category presentaban una considerable variedad de errores tipográficos: Sceond Class, StandardClass, Standadr Class, Fisrt Class, CConsumer, Cnosumer, Conumer, Corproate, Furniutre, Office Supplies, Office Suppies, entre muchas otras variantes. Mapear manualmente cada error a su forma canónica resultaba poco escalable y propenso a omisiones.

Se diseñó entonces una función auxiliar (`normalizar_texto`) que aplica un pipeline de cuatro pasos: (1) conversión a minúsculas y eliminación de espacios redundantes; (2) cotejo contra una lista de valores válidos esperados; (3) en caso de no encontrar coincidencia exacta, búsqueda por similitud aproximada mediante la función `get_close_matches` del módulo `difflib`, configurada con un umbral de similitud (`cutoff`) ajustado por columna; (4) fallback a Title Case si ninguna heurística previa resuelve el valor. Esta solución logró consolidar la totalidad de variantes legítimas reconocibles bajo las etiquetas canónicas:

- Ship Mode: Standard Class, Second Class, First Class, Same Day.
- Segment: Consumer, Corporate, Home Office.
- Category: Furniture, Office Supplies, Technology.

La función opera de manera conservadora: en lugar de eliminar registros con valores ambiguos, los preserva en formato Title Case para una eventual revisión manual posterior. Esta decisión se alinea con el principio de no destruir información cuando no es estrictamente necesario.

5.4 Tratamiento de valores nulos

La estrategia adoptada respondió a un criterio de severidad: distinguir entre campos críticos y campos no críticos. Se consideraron críticos aquellos cuya ausencia inhabilita por completo el análisis comercial: Sales, Quantity, Order Date, Ship Date, Order ID y Product ID. Los registros con nulos en cualquiera de estos campos fueron eliminados, dado que un pedido sin monto, cantidad o fecha no aporta valor analítico.

El impacto de esta eliminación fue cuantificado y resultó marginal: se descartaron 130 filas, equivalentes al 1,30 % del dataset original, lo cual se considera aceptable y muy por debajo del umbral del 5 % habitualmente referido en la literatura. El dataset depurado quedó conformado por 9.864 registros.

Para los campos no críticos (variables categóricas y descriptivas), se optó por no imputar valores ni eliminar registros, sino completar los nulos con la etiqueta «Sin dato». Esta convención preserva la información transaccional, hace explícita la ausencia de dato y permite cuantificar su impacto en cada análisis posterior. Esta diferenciación es relevante: imputar la moda en Region, por ejemplo, hubiese introducido sesgo geográfico artificial; imputar el nombre del cliente sería directamente inventar información.

6. Variables derivadas

Una vez consolidado el dataset depurado, se enriqueció con seis variables derivadas que abren nuevas dimensiones analíticas y facilitarán el modelado posterior en Power BI. Estas variables no aportan

información nueva en sentido estricto —se calculan a partir de las existentes—, pero hacen explícitos patrones temporales y comerciales que de otro modo permanecerían latentes.

Variable derivada	Fórmula	Propósito analítico
Shipping Days	Ship Date – Order Date	Mide la demora logística de cada pedido
Year	Año de Order Date	Permite cortes y comparaciones interanuales
Month	Mes (numérico) de Order Date	Análisis de estacionalidad
Month Name	Nombre del mes	Etiqueta legible para visualizaciones
Order Year-Month	AAAA-MM de Order Date	Serie temporal mensual continua
Profit Margin	Profit / Sales	Rentabilidad relativa de cada operación

El cálculo del margen de utilidad se protegió contra divisiones por cero mediante np.where, asignando NaN en aquellas líneas hipotéticas donde Sales fuera nulo. El control de calidad sobre Shipping Days confirmó la consistencia temporal del dataset: no se detectaron días de envío negativos (lo cual indicaría una fecha de envío anterior a la del pedido) y el rango quedó acotado entre 0 y 7 días, plenamente coherente con las modalidades de envío declaradas.

El dataset final quedó conformado por 9.864 registros y 27 columnas (21 originales más 6 derivadas), y fue exportado al formato Excel (.xlsx) para su consumo desde Power BI, con redondeo estandarizado a dos decimales en variables monetarias y cuatro decimales en variables porcentuales (Discount, Profit Margin).

7. Análisis exploratorio de datos y visualizaciones

Esta sección presenta los hallazgos del análisis exploratorio acompañados de las visualizaciones generadas en el notebook. Cada gráfico se complementa con su tabla de soporte y una lectura analítica que traduce el patrón estadístico en una interpretación de negocio.

7.1 Estadísticas descriptivas

El análisis descriptivo de las variables numéricas principales reveló las siguientes características distribucionales:

Variable	Media	Mediana	Desv. estándar	Mínimo	Máximo
Sales (USD)	230,27	54,86	622,92	0,44	22.638,48
Quantity (uds)	3,79	3,00	2,23	1	14

Variable	Media	Mediana	Desv. estándar	Mínimo	Máximo
Discount	0,16	0,20	0,21	0,00	0,80
Profit (USD)	28,65	8,67	234,51	-6.599,98	8.399,98
Shipping Days	3,96	4,00	1,75	0	7
Profit Margin	0,12	0,27	0,47	-2,75	0,50

La lectura conjunta de medias, medianas y desvíos estándar permite extraer varias observaciones de peso analítico. En primer lugar, Sales presenta una asimetría positiva muy marcada: la media (230,27 USD) cuadruplica a la mediana (54,86 USD), evidenciando una distribución de cola larga donde unas pocas transacciones de muy alto valor traccionan el promedio hacia arriba. En segundo lugar, Profit exhibe un fenómeno más preocupante: si bien su media (28,65 USD) es positiva, su desvío estándar (234,51 USD) es ocho veces superior, y su mínimo (-6.599,98 USD) revela la existencia de operaciones con pérdidas catastróficas. En tercer lugar, Discount muestra una distribución bimodal informal: los percentiles 25 y 50 ambos en 0,00 y 0,20 sugieren que la política comercial alterna entre «sin descuento» y «descuento del 20 %» como modalidades dominantes, con un grupo minoritario que recibe descuentos agresivos.

7.2 Análisis por categoría de producto

La agregación por categoría exhibe un patrón clásico en retail: el orden por volumen de facturación no coincide necesariamente con el orden por rentabilidad.

Categoría	Ventas (USD)	Ganancia (USD)	Unidades	Órdenes
Technology	803.592,53	137.998,24	6.704	1.505
Furniture	716.409,05	17.390,65	7.790	1.723
Office Supplies	702.314,73	119.472,92	22.222	3.658
Sin dato	49.044,60	7.716,34	698	190




Figura 1 — Ventas totales por categoría




Figura 2 — Ganancia total por categoría

La comparación lado a lado de ambos gráficos es la más reveladora del análisis por categoría. En el primero, las tres categorías principales (Technology, Furniture y Office Supplies) compiten cabeza a cabeza con barras de magnitud comparable: el negocio aparenta estar saludablemente diversificado. El segundo gráfico desmiente esa apariencia: Technology y Office Supplies sostienen el resultado económico con ganancias por encima de los 119.000 USD, mientras que Furniture —pese a su volumen— apenas aporta 17.390 USD. Esta asimetría se traduce en un margen efectivo del 2,4 % para Furniture, muy por debajo del 17 % que exhiben las otras dos categorías. La conclusión es directa: vender mobiliario genera tráfico de unidades pero compromete severamente el resultado económico de la operación consolidada.

7.3 Análisis por subcategoría

Bajar el nivel de detalle a subcategoría permite identificar con precisión quirúrgica los productos responsables de los desbalances observados a nivel categoría.




Figura 3 — Top 10 subcategorías por ventas

El ranking de las diez subcategorías más facturadoras está liderado por Chairs (320.516 USD) y Phones (315.661 USD), con Storage en tercer lugar (216.019 USD). El gráfico evidencia un mercado relativamente plano entre las posiciones cuarta y novena, lo que indica que la facturación está distribuida y no depende crítica-mente de un puñado de productos estrella.




Figura 4 — Subcategorías con menor ganancia total

Este es probablemente el gráfico más impactante del análisis. Las barras de Tables y Bookcases se extienden hacia el lado izquierdo del eje, indicando ganancias negativas: Tables registra una pérdida acumulada de -17.424 USD y Bookcases de -3.593 USD. Supplies aporta una pérdida menor (-988 USD). El hallazgo es contundente: dentro de la categoría Furniture, son específicamente las mesas y los estantes los responsables de la sub-performance. En el extremo opuesto, Copiers se destaca con 55.167 USD de ganancia generados con apenas 232 unidades vendidas, confirmando que la rentabilidad unitaria es muy superior en electrónica de oficina.

- **Tables:** cuarta subcategoría por ventas pero la peor performance del portafolio en términos absolutos. Cada mesa vendida deteriora el resultado neto.
- **Bookcases:** tendencia análoga a Tables aunque de menor magnitud relativa.
- **Supplies:** pérdida acotada pero persistente.

7.4 Análisis geográfico por región

La distribución geográfica del negocio muestra una concentración significativa en las regiones costeras:

Región	Ventas (USD)	Ganancia (USD)	Órdenes únicas	Margen ef. (%)
West	708.155,64	105.680,90	1.580	14,9 %
East	647.812,03	87.425,51	1.367	13,5 %
Central	490.819,51	39.095,07	1.153	8,0 %
South	382.350,88	45.693,26	814	11,9 %
Sin dato	42.222,85	4.683,41	199	11,1 %




Figura 5 — Ventas totales por región

La visualización ordena las regiones de mayor a menor facturación: West (708.155 USD), East (647.812 USD), Central (490.819 USD) y South (382.350 USD). Pero el dato verdaderamente revelador no se ve en el gráfico de barras sino en la tabla: West no sólo lidera en ventas sino que además exhibe el mejor margen efectivo (14,9 %). Central, en cambio, factura más de 490.000 USD pero su rentabilidad relativa cae al 8 % —prácticamente la mitad del promedio—. Este diferencial regional sugiere problemas operativos específicos en la zona central del país que ameritarían una investigación más profunda: costos logísticos diferenciales, política de descuentos local, o un mix de productos menos rentables vendido en esa región.

7.5 Análisis por segmento de cliente

El segmento Consumer concentra el grueso del negocio en términos de volumen, pero el ticket promedio cuenta una historia complementaria que matiza la lectura inicial.

Segmento	Ventas (USD)	Ganancia (USD)	Órdenes	Ticket prom.
Consumer	1.117.630,07	127.256,95	2.533	223,17
Corporate	684.946,31	90.161,85	1.489	234,57
Home Office	418.696,44	57.622,00	887	243,85
Sin dato	50.088,09	7.537,35	215	228,71




Figura 6 — Ventas totales por segmento

Consumer aporta el 51 % de las ventas totales (1.117.630 USD sobre 2.271.360 USD), pero su ticket promedio (223,17 USD) es el más bajo de los tres segmentos. Home Office, en cambio, factura menos en términos absolutos pero opera con el ticket más alto (243,85 USD), lo cual sugiere compras menos frecuentes pero más voluminosas. Esto define una segmentación natural en términos de estrategia comercial: para Consumer conviene optimizar la frecuencia de compra y el cross-selling; para Home Office conviene maximizar el valor por transacción mediante estrategias de upselling y cuentas dedicadas.

7.6 Evolución temporal de las ventas

La serie mensual de ventas entre enero de 2014 y diciembre de 2017 (48 puntos consecutivos) revela dos patrones simultáneos: una tendencia estructural de crecimiento sostenido y una estacionalidad marcada con picos recurrentes hacia el cierre de cada año calendario.




Figura 7 — Evolución mensual de ventas (2014 – 2017)

Los meses de noviembre y diciembre concentran sistemáticamente los máximos anuales, con un pico absoluto en noviembre de 2017 que supera los 117.000 USD facturados. Los meses de enero y febrero, por el contrario, representan los valles del ciclo, con caídas hasta el orden de los 4.500 USD. Esta estacionalidad —compatible con el ciclo comercial estadounidense centrado en Black Friday, Cyber Monday y la temporada navideña— tiene implicancias operativas concretas: el dimensionamiento del stock, la planificación logística y la disponibilidad de personal deberían ajustarse a esta curva. Adicionalmente, comparando los picos año tras año (~80.000 en 2014, ~95.000 en 2016, ~117.000 en 2017) se observa con claridad la tendencia secular de crecimiento del negocio.

7.7 Relación entre descuento y rentabilidad

El cruce entre nivel de descuento y ganancia constituye uno de los hallazgos más relevantes de todo el análisis. La tabla acumulada por nivel de descuento permite identificar con precisión el umbral crítico:

Descuento	Ventas (USD)	Ganancia (USD)	Operaciones
0 %	1.072.166,53	316.342,43	4.737
10 %	53.511,06	8.886,17	93
15 %	26.754,53	1.437,89	50
20 %	760.509,45	89.586,74	3.612
30 %	102.867,39	-10.303,41	224
40 %	113.022,95	-22.206,69	200
50 %	58.918,53	-20.506,49	66
60 %	6.636,92	-5.942,49	137
70 %	40.068,52	-39.350,92	411
80 %	16.926,60	-30.480,80	296




Figura 8 — Relación entre descuento y ganancia (muestra de 2.500 operaciones)

La visualización confirma de manera contundente lo que la tabla anticipa. Las nubes de puntos correspondientes a descuentos del 0 % y 20 % se mantienen mayoritariamente por encima de la línea horizontal en cero (referencia de break-even); a partir del 30 %, las nubes migran progresivamente hacia el cuadrante inferior, indicando pérdidas sistemáticas. La conclusión es inequívoca: el umbral del 30 % opera como una frontera estructural más allá de la cual el descuento deja de ser una herramienta comercial y se convierte en un mecanismo de destrucción de valor. En los niveles del 70 % y 80 % las pérdidas alcanzan magnitudes catastróficas (–39.350 USD y –30.480 USD respectivamente), sugiriendo que esas operaciones no obedecen a una lógica de promoción rentable sino, presumiblemente, a liquidaciones de stock o errores de pricing que ameritarían una auditoría específica.

7.8 Análisis logístico: tiempos de envío

La variable derivada Shipping Days, cruzada contra Ship Mode, valida la consistencia operativa de las modalidades de envío ofrecidas por la cadena:

Modalidad	Demora promedio	Mediana	Operaciones
Same Day	0,05 días	0	517
First Class	2,18 días	2	1.472
Second Class	3,24 días	3	1.888
Standard Class	5,01 días	5	5.763




Figura 9 — Distribución de días de envío según modo de envío

El box plot ordena las cuatro modalidades según su demora típica y permite leer simultáneamente tendencia central (la línea horizontal dentro de cada caja, la mediana), dispersión (la altura de la caja, el rango intercuartílico) y casos extremos (los puntos fuera de los bigotes). Same Day cumple plenamente con su promesa de envío (mediana en 0 días, una única observación atípica con un día de demora). Standard Class concentra el 58 % de los pedidos y opera con una mediana de 5 días, plenamente coherente con la oferta comercial. La consistencia entre la promesa logística y la performance observada es un indicador de salud operativa relevante: no se detectan desvíos sistemáticos entre lo prometido y lo entregado, lo cual habla bien del proceso de fulfillment.

8. Análisis RFM y segmentación de clientes

Una vez completado el análisis exploratorio sobre las ventas, el equipo avanzó hacia una dimensión analítica complementaria: el comportamiento de los clientes individuales. Mientras el EDA respondía a preguntas del tipo «¿qué se vende, dónde y con qué margen?», el análisis RFM responde a una pregunta cualitativamente distinta: «¿quiénes son los clientes que sostienen el negocio y cómo se les debe hablar a cada uno?».

El modelo RFM es una de las técnicas de segmentación más utilizadas en marketing analítico debido a su simplicidad metodológica y a su alto poder predictivo respecto al valor futuro de cada cliente. Su nombre proviene de las tres dimensiones que combina.

8.1 Marco conceptual

- **Recency (Recencia):** días transcurridos desde la última compra del cliente. Un valor bajo indica un cliente activo; un valor alto, un cliente que se está enfriando o ya se perdió.

- **Frequency (Frecuencia):** cantidad de órdenes únicas que el cliente ha realizado en el período observado. Mide la fidelidad operativa al canal.
- **Monetary (Monetario):** valor acumulado de las compras del cliente. Mide el aporte económico histórico al negocio.

La combinación de estas tres dimensiones permite construir un perfil tridimensional de cada cliente que un análisis univariado no podría revelar: un cliente con alto gasto histórico pero que hace dos años no compra no tiene el mismo valor estratégico que uno con menos gasto acumulado pero que sigue comprando regularmente.

8.2 Construcción del modelo

Se utilizó como base el dataset depurado df_clean. La fecha de referencia para el cálculo de la recencia se fijó en la última fecha de compra registrada en el dataset (diciembre de 2017), lo cual permite reconstruir la foto del negocio al cierre del período observado. Sólo se incluyeron registros con valores válidos en Customer ID, Order ID, Order Date y Sales.

Para cada cliente se calcularon las tres dimensiones y posteriormente se le asignó un puntaje del 1 al 5 a cada una utilizando quintiles (qcut sobre el ranking). En Recency los puntajes se invirtieron, dado que en esa dimensión menos días es mejor: un cliente con compra reciente recibe R_Score = 5. En Frequency y Monetary el orden es directo: más órdenes y más gasto reciben puntajes superiores.

8.3 Segmentación en siete grupos

La combinación de los tres puntajes (R, F, M) define un cubo conceptual con 125 celdas posibles (5×5×5). Aplicar políticas comerciales diferenciadas para cada una sería operativamente inviable; por eso se agruparon las celdas en siete segmentos comercialmente accionables, siguiendo el enfoque clásico del marketing relacional:

Segmento	Criterio (R-F-M)	Descripción
Champions	$R \geq 4, F \geq 4, M \geq 4$	Clientes recientes, frecuentes y de alto valor
Loyal	$R \geq 3, F \geq 4, M \geq 3$	Clientes con buena frecuencia y nivel de compra
At Risk	$R \leq 2, F \geq 4, M \geq 3$	Clientes valiosos que dejaron de comprar
Needs Attention	$R \leq 3, F \geq 3, M \geq 3$	Clientes con señales de enfriamiento
New Customers	$R \geq 4, F \leq 3$	Clientes recientes con baja frecuencia aún
Lost	$R \leq 2, F \leq 3$	Clientes inactivos de bajo valor histórico
Potential	Resto	Clientes intermedios con espacio para crecer

8.4 Composición y desempeño de la cartera

La aplicación del modelo a la base de 793 clientes únicos del período 2014–2017 arrojó la siguiente distribución:

Segmento	Clientes	% Clientes	% Revenue	Recencia (d)	Frec.	Ticket prom.	Revenue (USD)
Champions	103	13,0 %	23,8 %	24	9,3	5.241	539.832
Loyal	95	12,0 %	14,1 %	56	8,6	3.376	320.757
At Risk	64	8,1 %	14,2 %	208	8,7	5.049	323.158
Needs Attention	55	6,9 %	9,0 %	190	6,1	3.724	204.793
New Customers	151	19,0 %	15,9 %	26	5,0	2.387	360.500
Lost	201	25,3 %	13,2 %	355	4,0	1.489	299.295
Potential	124	15,6 %	9,8 %	83	6,0	1.799	223.026




Figura 10 — Distribución comparativa: % de clientes vs % de revenue por segmento RFM

La comparación entre los dos donuts es el hallazgo más relevante de toda la segmentación. En el donut izquierdo (composición por cantidad de clientes), Lost es el segmento más numeroso con 25 %; sin embargo, en el donut derecho (composición por revenue aportado), Lost apenas representa el 13 %. La asimetría inversa también es evidente: Champions representa apenas el 13 % de los clientes pero genera el 24 % del revenue. Esto confirma empíricamente el principio de Pareto aplicado a la cartera de clientes: una minoría concentra una proporción desproporcionada del valor económico generado.

8.5 Ranking de aporte económico




Figura 11 — Revenue acumulado histórico por segmento RFM

El gráfico de barras horizontales muestra el aporte económico absoluto de cada segmento. Champions encabeza con USD 540K, seguido por New Customers (USD 361K), At Risk (USD 323K) y Loyal (USD 321K). El dato más alarmante es la posición de At Risk en el tercer puesto del ranking de revenue: se trata de 64 clientes que históricamente han aportado más de USD 323.000 al negocio y que actualmente llevan en promedio 208 días sin comprar. Recuperar a este grupo es la oportunidad de mayor retorno por unidad de esfuerzo comercial.

Otro dato relevante es que Lost (clientes perdidos) aporta históricamente USD 299K acumulados pese a ser el segmento más numeroso. Su recencia promedio de 355 días los ubica prácticamente al borde de la inactividad anual, lo cual sugiere que el negocio enfrenta una tasa de churn estructural significativa que merece ser cuantificada y gestionada como métrica permanente.

8.6 Mapa de clientes: Recencia vs Frecuencia




Figura 12 — Mapa bidimensional de clientes con tamaño de burbuja proporcional al valor monetario

Este scatter combina simultáneamente las tres dimensiones del modelo: el eje X representa la recencia, el eje Y la frecuencia y el tamaño de cada burbuja el valor monetario acumulado. Los Champions (verde) se concentran en el cuadrante superior izquierdo: poca recencia, alta frecuencia. Los Lost (gris) se dispersan a la derecha del gráfico, indicando que llevan mucho tiempo sin comprar. La presencia de burbujas grandes color rojo (At Risk) hacia la mitad del eje X es particularmente significativa: son clientes de alto valor monetario que se están moviendo hacia el área de pérdida, y que sin intervención comercial migrarán al segmento Lost.

8.7 Plan de acción comercial por segmento

Cada segmento RFM admite una estrategia comercial diferenciada. La tabla siguiente sintetiza la acción recomendada y su justificación operativa:

Segmento	Acción comercial	Lógica subyacente
Champions	Fidelizar	Premiar, reconocer y proteger este núcleo crítico de revenue
Loyal	Upselling	Aumentar el ticket promedio con productos complementarios
At Risk	Reactivar urgente	Recuperar valor histórico antes de su migración a Lost
Needs Attention	Ofertas personalizadas	Frenar el enfriamiento con incentivos específicos
New Customers	Onboarding y educación	Convertirlos en compradores recurrentes
Lost	Campaña de win-back	Intentar recuperación masiva o aceptar baja definitiva

Segmento	Acción comercial	Lógica subyacente
Potential	Estímulo a la 2ª compra	Empujar el segundo pedido como punto de inflexión

Conviene observar que la prioridad no debe definirse exclusivamente por el tamaño del segmento sino por el producto entre tamaño, valor potencial recuperable y velocidad de degradación. Bajo este criterio combinado, los tres focos de acción inmediata deberían ser: protección de Champions (riesgo bajo pero impacto altísimo si se pierden), reactivación de At Risk (oportunidad alta) y aceleración de New Customers (cohorte de futuro).

9. Insights de negocio

Sintetizando el análisis exploratorio, el equipo identificó seis insights con potencial de impacto en la toma de decisiones del negocio.

Insight 1 — La rentabilidad no se distribuye proporcionalmente al volumen

Furniture vende casi lo mismo que Technology pero deja sólo el 13 % de su ganancia. Una empresa que mide su salud únicamente por facturación está leyendo de manera incompleta su propio desempeño. La métrica de cabecera debería ser el margen operativo por la línea de producto, no las ventas brutas.

Insight 2 — Tables y Bookcases son destructores de valor

Estas dos subcategorías facturan más de 310.000 USD combinados pero generan una pérdida acumulada de aproximadamente 21.000 USD. Su eliminación o rediseño profundo (renegociación de proveedores, cambio de precio, exclusión de la política de descuentos) podría liberar margen sin sacrificar share de mercado significativo, dado que los clientes que adquieren mesas suelen comprar otros productos en la misma orden.

Insight 3 — El umbral del 30 % de descuento es la frontera de la rentabilidad

Por debajo del 30 % los descuentos sostienen márgenes positivos; igualados o superados, el negocio pierde dinero de manera sistemática. Cualquier promoción que requiera descuentos del 50 % o más debería tener una justificación comercial muy específica (lanzamiento, rotación de stock crítico, fidelización estratégica) y operar bajo aprobación documentada.

Insight 4 — La región Central sub-performa en margen

Mientras West y East operan con márgenes efectivos cercanos al 14 %, Central cae al 8 %. La causa puede combinar una política de descuentos más agresiva, un mix de productos menos rentables o costos logísticos diferenciales. Una auditoría regional permitiría aislar el factor dominante y diseñar una respuesta específica.

Insight 5 — La estacionalidad de cuarto trimestre es predecible y aprovechable

Los picos de noviembre y diciembre se repiten año tras año con consistencia notable. Esta predictibilidad permite planificar el ciclo de aprovisionamiento, dimensionar la dotación operativa y diseñar campañas con anticipación, en lugar de reaccionar tardíamente a la demanda.

Insight 6 — El segmento Home Office tiene el mayor potencial de upselling

Su ticket promedio (243,85 USD) es el más alto, pero sólo realiza 887 órdenes únicas. Aumentar la frecuencia de compra de este segmento mediante programas específicos (cuentas dedicadas, suscripciones, ofertas personalizadas) tendría un impacto desproporcionado sobre la facturación total respecto a esfuerzos equivalentes en otros segmentos.

Insight 7 — El 25 % de los clientes (Champions + Loyal) genera el 38 % del revenue

El análisis RFM confirma empíricamente el principio de Pareto aplicado a la cartera: una minoría de 198 clientes sobre 793 sostiene casi cuatro de cada diez dólares facturados. Esta concentración es a la vez una fortaleza (alta lealtad de un núcleo identificable) y un riesgo (alta dependencia). La estrategia comercial debe priorizar la retención y protección de este segmento por encima de la captación masiva, dado que perder un Champion equivale, en términos económicos, a perder varios clientes del segmento Lost.

Insight 8 — At Risk es la oportunidad de mayor retorno potencial

Sesenta y cuatro clientes representan el 14,2 % del revenue histórico pero llevan en promedio 208 días sin comprar. Con un ticket promedio de USD 5.049 —el más alto del análisis— estos clientes ya demostraron capacidad de pago y conocimiento del catálogo. Una campaña de reactivación dirigida específicamente a este segmento podría aportar más valor incremental que una campaña de captación nueva, dado que el costo de adquisición ya está amortizado y el churn aún no es definitivo.

10. Conclusiones generales

El proyecto cumplió íntegramente con los objetivos planteados. El equipo logró transformar un dataset crudo de 9.994 filas y calidad deliberadamente deteriorada en un activo analítico de 9.864 filas, 27 columnas, libre de inconsistencias y enriquecido con variables derivadas que habilitan análisis temporales, geográficos y financieros.

Desde el punto de vista metodológico, la principal conclusión es que la preparación del dato no es una etapa accesoria sino el núcleo del trabajo analítico. Diagnosticar correctamente los problemas (tipos incorrectos, valores corruptos, errores tipográficos, pérdida de ceros en códigos postales, nulos selectivos) y resolver cada uno con la estrategia adecuada (conversión con coerce, normalización con coincidencia aproximada, imputación con etiqueta explícita, eliminación quirúrgica de registros críticos) consumió la mayor parte del esfuerzo y aportó la mayor parte del valor.

Desde el punto de vista comercial, el análisis exploratorio identificó una asimetría estructural entre volumen y rentabilidad. La categoría Furniture, traccionada por las subcategorías Tables y Bookcases, está deteriorando el resultado consolidado de la operación. Simultáneamente, la política de descuentos opera como un mecanismo de doble filo: hasta el 20 % refuerza el volumen sin sacrificar margen; a partir del 30 %, destruye valor sistemáticamente. Estos dos hallazgos solos justifican una intervención comercial inmediata.

Desde el punto de vista geográfico y de segmentación, se confirmó que el negocio está balanceado entre las cuatro regiones, con West como líder, pero exhibe una sub-performance preocupante en Central. La segmentación por tipo de cliente muestra que Consumer es el motor del volumen, pero Home Office es el segmento con mayor potencial de upselling. La estacionalidad del último trimestre es predecible y debería integrarse a la planificación operativa.

La incorporación del análisis RFM agregó al estudio una dimensión de Customer Analytics que el EDA tradicional no captura. El modelo permitió clasificar a los 793 clientes únicos del período en siete segmentos accionables y cuantificar la asimetría estructural entre cantidad de clientes y aporte económico: el 25 % superior de la cartera (Champions y Loyal) sostiene casi el 38 % del revenue, mientras que el 25 % inferior (Lost) aporta sólo el 13 % y opera con una recencia promedio de 355 días. Particularmente revelador resultó el segmento At Risk: 64 clientes con un ticket promedio de USD 5.049 que llevan más de medio año sin comprar y representan la mayor oportunidad de recuperación de valor con el menor costo de adquisición.

Finalmente, desde el punto de vista de presentación, la entrega de un dataset depurado y exportado a formato Excel permite que el equipo de negocio consuma estos hallazgos directamente desde Power BI, asegurando reproducibilidad y trazabilidad. El presente informe se entrega como soporte documental de las decisiones técnicas y analíticas adoptadas durante todo el proceso.

11. Recomendaciones y mejoras futuras

Recomendaciones para el negocio

- **Revisar la oferta de Tables y Bookcases.** Renegociar costos con proveedores, revisar precios de venta o, eventualmente, retirar referencias no rentables del catálogo.
- **Establecer un techo formal de descuento del 25 %.** Cualquier descuento superior debería requerir aprobación explícita y una justificación comercial documentada.
- **Auditar el desempeño de la región Central.** Identificar si la sub-performance en margen se debe al mix de productos, a la política de descuentos local o a costos logísticos.
- **Diseñar un programa de fidelización para Home Office.** El segmento tiene el ticket promedio más alto pero la menor frecuencia: aumentar las órdenes por cliente tendría un impacto desproporcionado.

- **Planificar el ciclo de stock alineado a la estacionalidad de Q4.** Los picos de noviembre y diciembre son predecibles y deben anticiparse con compras y dotación.
- **Lanzar una campaña de reactivación dirigida al segmento At Risk.** 64 clientes con ticket promedio de USD 5.049 llevan más de 200 días sin comprar; recuperarlos genera más valor que la captación masiva equivalente.
- **Diseñar un programa de protección para Champions y Loyal.** El 25 % superior de la cartera aporta el 38 % del revenue; perder uno de estos clientes equivale económicamente a perder varios del segmento Lost.

Mejoras técnicas y analíticas futuras

- Implementar un pipeline automatizado de carga y limpieza utilizando Apache Airflow o Prefect, de modo que las reglas de normalización aplicadas en este TP queden codificadas como un proceso reproducible y no como un trabajo de única vez.
- Incorporar análisis estadístico inferencial: tests de hipótesis para validar formalmente diferencias entre regiones y segmentos, intervalos de confianza para las métricas de margen y análisis de varianza por categoría.
- Desarrollar modelos predictivos a partir del dataset limpio: pronóstico de ventas mensuales mediante series temporales (ARIMA, Prophet), modelo de clasificación para predecir órdenes rentables versus no rentables, segmentación de clientes mediante clustering.
- Construir un tablero ejecutivo en Power BI con KPIs alineados a los insights del informe: margen por categoría, distribución de descuentos, evolución regional, ranking de subcategorías deficitarias.
- Validar el dataset contra fuentes externas para detectar potenciales sesgos o errores no detectados en el diagnóstico inicial, como por ejemplo la validación de códigos postales contra una base oficial del USPS.
- Integrar dimensiones adicionales no presentes en el dataset actual: costos unitarios reales por producto, márgenes objetivo por categoría, presupuesto comercial por región. Esto permitiría pasar de un análisis descriptivo a uno verdaderamente prescriptivo.
- Convertir el análisis RFM en un proceso recurrente con frecuencia mensual o trimestral, monitoreando la migración de clientes entre segmentos a lo largo del tiempo. La velocidad con la que un Champion migra hacia Loyal o un Loyal hacia At Risk es un indicador temprano de salud comercial mucho más sensible que las métricas agregadas tradicionales.

12. Anexo técnico — Notebook de Google Colab

El presente anexo describe la estructura del notebook desarrollado en Google Colab que soporta todo el trabajo analítico aquí presentado. Su lectura permite reproducir el proceso, auditar las decisiones y eventualmente extender el análisis.

Entorno de ejecución

- Plataforma: Google Colab (Python 3).
- Archivo de entrada: `df_sales_crudo.csv`.
- Archivo de salida: `df_sales_limpio_para_powerbi.xlsx`.

Bibliotecas utilizadas

- pandas y NumPy para manipulación y cálculo numérico.
- Matplotlib y Seaborn para visualización estadística (`set_theme` con estilo `whitegrid`).
- `re`, `pathlib` y `diffli` (módulos estándar) para tareas auxiliares de limpieza.
- `openpyxl` como motor de escritura del archivo Excel final.

Organización del notebook

El notebook se estructura en catorce secciones numeradas que reproducen el flujo lógico del proyecto:

- Secciones 1 – 2: preparación del entorno, carga del dataset y primera inspección general.
- Sección 3: revisión de problemas puntuales (tipos, valores corruptos, longitud de códigos postales).
- Sección 4: limpieza y transformación —conversiones de tipo, normalización categórica, tratamiento de nulos—.
- Sección 5: construcción de variables derivadas.
- Sección 6: exportación del dataset depurado al formato Excel para consumo desde Power BI.
- Sección 7: estadísticas descriptivas avanzadas.
- Secciones 8 – 13: análisis por categoría, subcategoría, región, segmento, evolución temporal, descuentos y tiempos de envío.
- Sección 14: análisis RFM y segmentación de la cartera de clientes en siete grupos accionables, con plan de acción comercial diferenciado por segmento.

Estilo de código

El equipo adoptó deliberadamente un estilo de codificación claro y didáctico, con comentarios en primera persona del plural, breves y orientados a explicar el «por qué» de cada decisión más que el «qué». Las celdas se mantuvieron pequeñas y enfocadas en una única responsabilidad, facilitando la lectura secuencial. El dataset original se preservó intacto en `df_raw` a lo largo de todo el flujo, trabajándose siempre sobre copias (`df`, `df_clean`) para garantizar la trazabilidad.

Reproducibilidad

Cualquier integrante del equipo puede reproducir el análisis ejecutando las celdas en orden secuencial desde una sesión limpia de Colab, siempre que se mantengan las rutas declaradas en Google Drive y se respete la versión original del archivo crudo. El producto final —el archivo

df_sales_limpio_para_powerbi.xlsx— constituye la entrega operativa del proyecto y la base sobre la cual se construirá el tablero ejecutivo en Power BI.

— Fin del informe —

IFTS N° 18 · Proyecto Integrador · Ciclo 2026